

Cadeias de Markov

?!

- O que esteve na origem do grande sucesso inicial da Google ?
- O que tem em comum esse sucesso com a capacidade de interagir por voz com computadores, robôs e smartphones ?
 - No reconhecimento de fala ?
 - Na síntese de fala ?
- E com a modelação do comportamento de uma ligação de rede sujeita a falhas?

Exemplo 1

- Suponhamos que em cada dia que têm aulas TP de MPECI acordam e decidem se vêm ou não à aula.
- Se vieram à aula anterior, a probabilidade de virem é 70%;
- se faltaram à anterior, essa probabilidade é 80%
- Algumas questões: *imaginando uma aula na 2ª e outra na 4ª*
 - Se vieram à aula esta segunda, qual a probabilidade de virem na aula de **SEGUNDA** da próxima semana ?
 - Assumindo que o semestre tem duração infinita, qual a percentagem aproximada de aulas a que estariam presentes ?


Exemplo 2

prob do estado seguinte depende do estado corrente

- Imagine uma ligação entre dois computadores ($A \rightarrow B$) que, a cada **intervalo de tempo discreto** (slot), pode estar em um de **dois estados**:
- **Bom (B)**: a transmissão é bem-sucedida.
- **Mau (M)**: a ligação está degradada (pacote perdido).
- O estado no instante seguinte **depende apenas do estado atual**; se a ligação está no estado **B** tem probabilidade 90% de se manter nesse estado, se está no estado **M** tem probabilidade de 50% de se manter no mesmo estado.
- Em média quanto tempo estará a ligação em cada um dos estados?

Outro exemplo

- Passeio aleatório (random walk)



Cara Coroa Coroa ... Cara ...

Muitas áreas de aplicação

- Muitas vezes estamos interessados na transição de algo entre certos estados.
- Exemplos:
 - Movimento de pessoas entre regiões
 - Estado do tempo
 - Movimento entre as posições num jogo de Monopólio
 - Pontuação ao longo de um jogo
 - Estado de Filas de atendimento

Princípios básicos


Processos estocásticos

↳ conjunto de variáveis aleatórias

- Estendem o conceito de variável aleatória
- Lidam com a dinâmica da teoria de probabilidades
- Uma v.a. X mapeia um acontecimento $s \in \Omega$ num número $X(s)$
- O processo mapeia o acontecimento para números diferentes em tempos diferentes
conjunto de sequências possíveis
 - O que implica que em lugar de termos um número $X(s)$ temos $X(t, s)$
 - Sendo $t \in T$ geralmente um conjunto de tempos

Processos estocásticos

- 3 realizações de um processo estocástico





- Se fixarmos s , $X(t)$ é uma função real do tempo
- $X(t, s)$ pode então ser vista como uma **coleção de funções no tempo**
- Se fixarmos t temos uma função $X(s)$ que depende apenas de s , ou seja é uma variável aleatória
- Um nome alternativo é processos aleatórios

Classificação de processos estocásticos

- Podem ser classificados segundo t e os valores que pode assumir (estados do processo)
- Quanto ao tempo :
 - Tempo contínuo: Se tempo é um intervalo contínuo
 - Tempo discreto: Se o tempo é um conjunto contável
 - Também chamada sequência aleatória e representada por $X[n]$
- Quanto ao conjunto de estados (E):
 - Contínuo
 - Discreto

Estados



Definição

- Um **processo de Markov** é um **processo estocástico** em que a probabilidade de o sistema **estar num estado** específico num determinado período de observação **depende apenas do seu estado** no período de observação imediatamente **precedente**
 - O futuro apenas depende do presente e não do passado

Tipos de processos de Markov

n vamos pegar nestes

		Espaço de estados	
		Discreto	Contínuo
Tempo	Discreto	Cadeia de Markov de tempo discreto	Processo de Markov em tempo discreto
	Contínuo	Cadeia de Markov de tempo contínuo	Processo de Markov em tempo contínuo

- Focaremos a nossa atenção em **cadeias de Markov de tempo discreto e de tempo contínuo** com espaço de estados discreto (isto é, com um número de estados finito ou infinito, mas contável).

Cadeias de Markov de tempo e estados discretos

- X_n : estado após n transições
 - Pertence a um conjunto finito (em alguns casos pode ser um conjunto infinito mas contável),
 - Em geral $\{1, 2, \dots, m\}$
 - X_0 é dado ou aleatório (estado inicial)

↑
é preciso saber
sempre o estado inicial

Questões comuns relativas a cadeias de Markov

- Qual é a probabilidade de transitar do estado i para o estado j em n passos?
- Existe uma distribuição estacionária (ou estado de equilíbrio)?
- A cadeia converge para essa distribuição a longo prazo (independentemente do estado inicial)?

Propriedade de Markov

- Probabilidade de **transição do estado i para o estado j** :
matriz de transição P_{ij} é transposta de P_{ji}
- $\mathbf{p_{ji}} = P(X_{n+1} = j | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0)$
 $\nwarrow$ estado no estado i no instante n , passar para o estado j no instante $n+1$
 $= P(X_{n+1} = \mathbf{j} | X_n = \mathbf{i})$
- Quando estas probabilidades $\mathbf{p_{ji}}$ não dependem de n a cadeia diz-se **homogénea**
— Focaremos a nossa atenção neste tipo de cadeias de Markov
instante de tempo


Propriedade de Markov

- $P(X_0 = x_0, X_1 = x_1, X_2 = x_2 \dots) = ?$

$$= P(X_0 = x_0) P(X_1 = x_1 | X_0 = x_0) P(X_2 = x_2 | X_0 = x_0, X_1 = x_1) \dots$$

$$= P(X_0 = x_0) P(X_1 = x_1 | X_0 = x_0) P(\mathbf{X_2 = x_2 | X_1 = x_1}) \dots$$

- O processo “não tem memória” - *só depende do estado presente*



Especificação de uma cadeia

- Identificar os **estados** possíveis
- Identificar as **transições** possíveis $p \neq 0$
- Identificar as **probabilidades de transição**

Aplicando ao exemplo 1 – faltar ou não faltar à aula


- Estados ?
- Transições ?
- Probabilidades de transição ?

Aplicando ao exemplo 1 – faltar ou não faltar à aula

- Estados ?
 - 2: {faltar, não faltar}
- Transições ?
 - Não faltar -> não faltar
 - Faltar -> não faltar
 - Não faltar -> faltar
 - Faltar -> faltar
- Probabilidades de transição ?
 - Não faltar -> não faltar: 0,7
 - Faltar -> não faltar : 0,8
 - Não faltar -> faltar : 0,3
 - Faltar -> faltar : 0,2

Matriz de transição

- É usual representar as probabilidades de transição através de uma matriz, **chamada de matriz de transição**
- Tendo o sistema n estados possíveis, para cada par i, j fazemos t_{ji} igual à probabilidade de mudar **do estado i para o estado j** .
- A matriz T cujo valor na posição linha = j , coluna = i é t_{ji} é a **matriz de transição**



- Nota: Alguns autores adoptam t_{ij} como a probabilidade de mudar do estado i para o estado j *transposta*

Matriz T do Exemplo 1

- $T = \begin{pmatrix} ? & ? \\ ? & ? \end{pmatrix}$
- Considerando estado 1 “não faltar”, temos
- $T = \begin{matrix} \text{não faltar} \\ \text{faltar} \end{matrix} \begin{matrix} \xrightarrow{\text{de}} \\ \rightarrow \end{matrix} \begin{pmatrix} 0,7 & 0,8 \\ 0,3 & 0,2 \end{pmatrix} \begin{matrix} \\ \text{para} \end{matrix}$
 $= 1$

Matriz T do Exemplo 2

$$T = \begin{matrix} & \begin{matrix} B & M \end{matrix} \\ \begin{matrix} B \\ M \end{matrix} & \begin{bmatrix} 0,9 & 0,5 \\ 0,1 & 0,5 \end{bmatrix} \end{matrix}$$

↑ prob de, estando
no estado M , passar
para estado M

Matriz T é estocástica


- A matriz de transição reflecte propriedades importantes das probabilidades:
 - Todas as entradas são não-negativas
 - Os valores em **cada COLUNA** somados dão sempre resultado 1
- Devido a estas propriedades a matriz é denominada de **matriz estocástica**

Representação gráfica da cadeia

- Adequada e possível para número de estados pequeno
- **Nós**: representam todos os estados
- **Setas**: para todas as transições permitidas (one-step)
 - Ou seja, seta entre i e j apenas de $p_{ji} > 0$

Representação gráfica da cadeia

- Exemplo:



soma das saídas
de qualquer estado = 1

Simulação / Visualização dinâmica

- Estão disponíveis online formas de visualizar as transições entre estados ao longo do tempo ...
- Um desses exemplos é **Markov Chains - A visual explanation by [Victor Powell](#)**

- <http://setosa.io/blog/2014/07/26/markov-chains/index.html>

Que inclui:

- <http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.5%2C0.5%5D%2C%5B0.5%2C0.5%5D%5D%7D>

- Para usar precisamos apenas de introduzir a matriz T
 - Que define o número de estados, quais as transições possíveis e as probabilidades associadas a essas transições (Nota: a notação é diferente da usada em MPECI)

Simulando os nossos exemplos

- Exemplo 1:
 - Matriz:
[[0.7, 0.3],
[0.8, 0.2]]
 - <http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.7%2C0.3%5D%2C%5B0.8%2C0.2%5D%5D%7D>
- Outro exemplo
 - [[0,1,0,0],
[0,0,1,0],
[0,0,0,1],
[0.2,0.3,0.3,0.2]]
 - O que vamos ver ?
 - Acesso directo:
<http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0%2C1%2C0%2C0%5D%2C%5B0%2C0%2C1%2C0%5D%2C%5B0%2C0%2C0%2C1%5D%2C%5B0.2%2C0.3%2C0.3%2C0.2%5D%5D%7D>

Estado da cadeia num determinado instante

- O **estado** de uma cadeia de Markov com n estados no tempo (time step) k é dado pelo **vector estado**

$$\mathbf{x}^{(k)} = \begin{pmatrix} p_1^{(k)} \\ p_2^{(k)} \\ \vdots \\ p_n^{(k)} \end{pmatrix}$$

- Onde $p_j^{(k)}$ é a probabilidade de o sistema estar no estado j no instante de tempo k

Vector estado/probabilidade

- Considerando o exemplo 1:
- Suponhamos que após 10 aulas a probabilidade de faltar e não faltar são iguais
- Então o vector representativo do estado (state vector) seria:

$$\mathbf{x}^{(10)} = \begin{pmatrix} 0,5 \\ 0,5 \end{pmatrix}$$

- Este vector também se designa por **vector de probabilidade**
 - Todos os elementos não-negativos
 - Soma dos elementos igual a um

Exemplo 2

- Supondo que no instante 0 a ligação tem o triplo da probabilidade de estar no estado Bom do que no estado Mau o vetor de probabilidade é:

$$\mathbf{x}^{(0)} = \begin{pmatrix} 0,75 \\ 0,25 \end{pmatrix}$$

Vector estado após uma transição


- Como obter $\mathbf{x}^{(k+1)}$?
- O vector de estado $\mathbf{x}^{(k+1)}$ no período de observação $k + 1$ pode ser determinado a partir do vector $\mathbf{x}^{(k)}$ através de:

$$\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)}$$

- Que resulta da probabilidade condicional:
- $P(\text{estado } j \text{ em } t = k + 1)$
$$= \sum_{i=1}^n P(\text{transição do estado } i \text{ para o } j)P(\text{estado } i \text{ em } t = k)$$

Exemplo de aplicação – Exemplo 1

- De que forma depende a probabilidade de ir à aula seguinte da probabilidade de estar na aula actual ?



Estado após múltiplas transições


- Ataquemos agora problemas do “tipo”:
 - Qual é a probabilidade de transitar do estado i para o estado j em n passos?
- Exemplo 1:
 - Qual a probabilidade de um aluno que veio à aula de uma segunda vir também à aula na segunda seguinte? – duas aulas depois
 - Assumindo as probabilidades do nosso exemplo !
 - Tendo em conta que temos aulas segunda e quarta (TP1).

Equações de Chapman-Kolmogorov

- Definindo a transição em n passos $p_{ji}^{(n)}$ como a probabilidade de **um processo no estado i se encontrar no estado j após n transições** adicionais. Ou seja:
- $p_{ji}^{(n)} = P(X_{n+k} = \textcolor{blue}{j} | X_k = \textcolor{blue}{i}), \quad n \geq 0, i, j \geq 0$
- Obviamente $p_{ji}^{(1)} = p_{ji}$
- As **equações de Chapman-Kolmogorov** permitem calcular estas probabilidades

$$p_{ji}^{(n+m)} = \sum_k p_{ki}^{(n)} p_{jk}^{(m)} \quad \forall n, m \geq 0, \forall i, j$$

Interpretação



Interpretação

- É fácil de compreender se tivermos em conta que $p_{ki}^{(n)} p_{jk}^{(m)}$ representa a probabilidade de:
 - Começando em i o processo ir para o estado j em $n + m$ transições..
 - Através de um caminho que o leva ao estado k na transição n
- Logo, somando para todos os estados intermédios k obtém-se a probabilidade de estar no estado j ao fim de $n + m$ transições

Em termos de matrizes

- Se usarmos $\mathbf{T}^{(n)}$ para representar a matriz com as probabilidades de n transições, a equação anterior transforma-se em:


$$\mathbf{T}^{(n+m)} = \mathbf{T}^{(n)} * \mathbf{T}^{(m)}$$

Em que o “*” significa multiplicação de matrizes

- Desta equação obtém-se facilmente:

ao fim de 2 iterações $\rightarrow \mathbf{T}^{(2)} = \mathbf{T}^{(1+1)} = \mathbf{T} * \mathbf{T} = \mathbf{T}^2$

- E por indução $\mathbf{T}^{(n)} = \mathbf{T}^{(n-1+1)} = \mathbf{T}^{n-1} * \mathbf{T} = \mathbf{T}^n$
 - Ou seja, a matriz de transição relativa a n transições pode ser obtida multiplicando $\mathbf{T}$ por si própria n vezes



Aplicação ao Exemplo 1

- Voltando a uma questão colocada no início da aula ...
- *Se vieram à aula esta segunda, qual a probabilidade de virem na aula de **SEGUNDA** da próxima semana ?*
- Solução:
- Temos $\mathbf{x}^{(0)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, significando “não faltar”
- Pretendemos $\mathbf{x}^{(2)}$, instante 0 = hoje, 2 aulas por semana

...

- $\mathbf{x}^{(2)} = T\mathbf{x}^{(1)} = T(T\mathbf{x}^{(0)}) = T^2\mathbf{x}^{(0)}$

$$\begin{aligned} &= \begin{pmatrix} 0,7 & 0,8 \\ 0,3 & 0,2 \end{pmatrix}^2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0,7 & 0,8 \\ 0,3 & 0,2 \end{pmatrix} \begin{pmatrix} 0,7 \\ 0,3 \end{pmatrix} \\ &= \begin{pmatrix} 0,73 \\ 0,27 \end{pmatrix} \end{aligned}$$

- Ou seja probabilidade de 0,73 de virem na próxima segunda

Terminologia



Tipos de estados

Tipos de matrizes de transição

...


Acessibilidade de um estado

- Possibilidade de ir do estado i para o estado j (existe caminho na cadeia de i para j).



Estados comunicantes

- Dois estados comunicam se ambos são acessíveis a partir do outro.




- Um sistema é não redutível (irreducible) se todos os estados comunicam
- Classe:** conjunto de estados que comunicam entre si

Estado recorrente

- Um estado s_i é um **estado recorrente** se o sistema puder sempre voltar a ele (depois de sair dele).
- De uma forma mais formal: s_i é um **estado recorrente** se, para todos os estados s_j , a existência de um inteiro r_j tal que $p_{ji}^{(r_j)} > 0$ implica que existe um inteiro r_i tal que $p_{ij}^{(r_i)} > 0$
- Um estado não recorrente é transiente

Estados recorrentes ?



- Os 3 estados são recorrentes


Estado transiente

- Um estado é transiente se **existe um outro estado qualquer para o qual o** processo de Markov **pode transitar, mas do qual o processo não pode retornar**
- Ou seja, se existe um estado s_j e um inteiro l tal que $p_{ji}^{(l)} \neq 0$ e $p_{ij}^{(r)} = 0$ para $r = 0, 1, 2, \dots$
- A probabilidade destes estados tende para zero quando n tende para infinito
 - Pois apenas são visitados um número finito de vezes


Estado periódico

- Um estado é **periódico** se apenas se pode regressar a ele após um número fixo de transições superior a 1 (ou múltiplos desse número).
- Formalizando:
 - Um estado recorrente s_i diz-se **periódico** se existe um inteiro $c > 1$ tal que $p_{ii}^{(r)}$ é igual a zero para todos os valores de r excepto $r = c, 2c, 3c, \dots$

Estado periódico



Todos estados visitados em múltiplos de 3 iterações




Todos estados visitados em múltiplos de 3 iterações

- Um estado não periódico é **aperiódico**
 - Como era de esperar!

Estado absorvente

- Um estado **absorvente** é um **estado do qual não é possível sair** (ou seja transitar para outro estado)
- Uma cadeia é absorvente se tiver pelo menos um estado absorvente




estado transitiente - após um tempo não vai ser possível voltar a ele

- Os estados 0 e 4 são absorventes

Aplicação dos conceitos

- Exemplo:

State	0	1	2	3
0	0	X	X	0
1	X	0	0	0
2	0	0	0	X
3	X	0	0	X



- Todos os pares de estados comunicam, formando um única classe recorrente
 - Os estados são aperiódicos
- Em consequência o processo é aperiódico e irreduzível - todos comunicam entre si

Assuntos principais dados anteriormente

- Noção de processo estocástico
- Cadeias de Markov
- Propriedade de Markov
- Matriz de transição T
- Representação gráfica
- $\mathbf{T}^{(n)}$

Demos

- **Wolfram:**
 - **Finite-State, Discrete-Time Markov Chains**
 - <http://demonstrations.wolfram.com/ATwoStateDiscreteTimeMarkovChain/>
 - <http://demonstrations.wolfram.com/FiniteStateDiscreteTimeMarkovChains/>

O que acontece ao fim de muitas
transições ?

Potências de T quando $n \rightarrow \infty$

- Exemplo 2 (3 grupos de alunos):
- Vejamos o comportamento de T^n ao aumentar n ...

$$T = \begin{pmatrix} 0.333333 & 0.25 & 0. \\ 0.333333 & 0.5 & 0.5 \\ 0.333333 & 0.25 & 0.5 \end{pmatrix}$$

$$T^2 = \begin{pmatrix} 0.194444 & 0.208333 & 0.125 \\ 0.444444 & 0.458333 & 0.5 \\ 0.361111 & 0.333333 & 0.375 \end{pmatrix}$$

$$T^3 = \begin{pmatrix} 0.175926 & 0.184028 & 0.166667 \\ 0.467593 & 0.465278 & 0.479167 \\ 0.356481 & 0.350694 & 0.354167 \end{pmatrix}$$

$$T^4 = \begin{pmatrix} 0.17554 & 0.177662 & 0.175347 \\ 0.470679 & 0.469329 & 0.472222 \\ 0.353781 & 0.353009 & 0.352431 \end{pmatrix}$$

$$T^5 = \begin{pmatrix} 0.176183 & 0.176553 & 0.176505 \\ 0.470743 & 0.47039 & 0.470775 \\ 0.353074 & 0.353057 & 0.35272 \end{pmatrix}$$

$$T^6 = \begin{pmatrix} 0.176414 & 0.176448 & 0.176529 \\ 0.470636 & 0.470575 & 0.470583 \\ 0.35295 & 0.352977 & 0.352889 \end{pmatrix}$$

Continuando... (em Matlab)

% n = 10

Tn =

0.1765 0.1765 0.1765

0.4706 0.4706 0.4706

0.3529 0.3529 0.3529


% n=100

Tn =

0.1765 0.1765 0.1765

0.4706 0.4706 0.4706


0.3529 0.3529 0.3529



tende para valor de estados fixo

Exemplo 1 (faltar/não faltar)

```
T=[0.7 0.8  
    0.3 0.2]  
Tn= T;  
pij= Tn(:);  
for n=2:10  
    Tn= T*Tn;  
    pij=[ pij Tn(:)];  
    plot(pij')  
    drawnow  
end  
Tn
```



$T_n =$

0.7273	0.7273
0.2727	0.2727

Questões ?

- Converge ?
- Para quê ?

Equilíbrio

- As cadeias dos nossos exemplos atingem um equilíbrio.
- Quando isso acontece a probabilidade de qualquer estado torna-se constante independentemente do passo (step) e das condições iniciais *nº de iterações*
- Para analisar essa situação é necessário considerar um certo tipo de cadeias de Markov...

Matriz/ Processo regular

- A matriz de transição (ou o processo de Markov correspondente) é **regular** se alguma potência da matriz tem todos os valores não-nulos.
 - Existe uma **probabilidade de mudar de qualquer estado para qualquer estado**
- Qualquer matriz de transição sem elementos nulos é uma matriz regular.
- No entanto, uma matriz contendo elementos nulos pode ser regular.
 - Por exemplo: $T = \begin{bmatrix} 0 & 0 & 0.5 \\ 1 & 0 & 0.5 \\ 0 & 1 & 0 \end{bmatrix}$

...

- No caso de matrizes com elementos nulos, pode verificar-se se é regular substituindo os elementos não-nulos por “X” e calculando potências sucessivas
- No nosso exemplo:

$$\bullet \quad T = \begin{bmatrix} 0 & X & 0 \\ 0 & 0 & X \\ X & X & 0 \end{bmatrix}, T^2 = \begin{bmatrix} 0 & 0 & X \\ X & X & 0 \\ 0 & X & X \end{bmatrix} \dots, T^8 = \begin{bmatrix} X & X & X \\ X & X & X \\ X & X & X \end{bmatrix}$$

Cadeia **ergódica**

- Uma cadeia de Markov diz-se ergódica se é possível efectuar transições de qualquer estado para qualquer outro estado
- Em consequência, uma cadeia regular é também ergódica

Cadeia ergódica

- No entanto, **nem todas as cadeias ergódicas são regulares**
 - Exemplo: se de um determinado estado se pode transitar para alguns estados apenas num número par de transições e para outros num número ímpar de transições, então todas as potências da matriz de transição terão elementos nulos

$$T = \begin{bmatrix} 0 & 0.5 & 0 \\ 1 & 0 & 1 \\ 0 & 0.5 & 0 \end{bmatrix}$$

...

- Potências pares

```
>> T^30
```

```
ans =
```

```
0.5000    0    0.5000
    0 1.0000    0
0.5000    0    0.5000
```

```
>> T^100
```

```
ans =
```

```
0.5000    0    0.5000
    0 1.0000    0
0.5000    0    0.5000
```

- Potências ímpares

```
>> T^5
```

```
ans =
```

```
    0    0.5000    0
1.0000    0 1.0000
    0    0.5000    0
```

```
>> T^51
```

```
ans =
```

```
    0    0.5000    0
1.0000    0 1.0000
    0    0.5000    0
```

engodica mas não regular

$$\lim_{n \rightarrow \infty} T^n$$

- Se T é a matriz de transição de um processo de Markov **regular** então:
- $\lim_{n \rightarrow \infty} T^n$ é a matriz:

$$A = \begin{bmatrix} u_1 & u_1 & \cdots & u_1 \\ u_2 & u_2 & \cdots & u_2 \\ \cdots & \cdots & \cdots & \cdots \\ u_N & u_N & \cdots & u_N \end{bmatrix}$$

Com todas as colunas idênticas

- Cada coluna $\mathbf{u}$ é um vector probabilidade em que todas as componentes são positivas

Vector estado estacionário ^{em regime} / ^{vetor limite} (steady-state vector)

- Sendo T uma matriz de transição regular e $\mathbf{A}$ e $\mathbf{u}$ o resultado de $\lim_{n \rightarrow \infty} T^n$ (slide anterior), demonstra-se que:

- a) Para qualquer vector de probabilidade $\mathbf{x}$, $T^n \mathbf{x} \rightarrow \mathbf{u}$ quando $n \rightarrow \infty$

Sendo $\mathbf{u}$ o vector estado estacionário (**steady-state vector**)

- b) $\mathbf{u}$ é o único vector de probabilidade que satisfaz a equação matricial $\mathbf{T}\mathbf{u} = \mathbf{u}$
- c) $\lim_{n \rightarrow \infty} \left(\frac{\eta(i,n)}{n} \right) = \mathbf{u}(i)$, em que $\eta(i,n)$ é o número de visitas ao estado i em n passos (transições)

Cálculo do vector estado estacionário

- Sabemos que o vector correspondente ao estado estacionário é único.
- Usamos a equação que ele satisfaz para o calcular: $\mathbf{T}\mathbf{u} = \mathbf{u}$
- Ou, na forma matricial, $(\mathbf{T} - \mathbf{I})\mathbf{u} = 0$

Exemplo 1 (aulas)

- $\mathbf{T}\mathbf{u} = \mathbf{u}$

- $$\begin{bmatrix} 0,7 & 0,8 \\ 0,3 & 0,2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}$$

- $$\begin{cases} \frac{7}{10}u_1 + \frac{8}{10}u_2 = u_1 \\ \frac{3}{10}u_1 + \frac{2}{10}u_2 = u_2 \end{cases} = \begin{cases} \frac{-3}{10}u_1 + \frac{8}{10}u_2 = 0 \\ \frac{3}{10}u_1 + \frac{-8}{10}u_2 = 0 \end{cases}$$
$$\begin{matrix} u_1 + u_2 = 1 \end{matrix}$$

- ...

Em Matlab

Uma possível solução:

% matriz de transição

T=[7 8; 3 2]/10

% (T-I)u aumentado com
u1+u2 *matriz identidade*

M=[T-eye(2);
ones(1,2)]

%

x=[0 0 1]' *← $\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$*

% resolver para obter u

u=M\x

Resultado:

0.7273

0.2727

Ou seja aprox. 72 % de
probabilidade de não
faltarem



Exemplo1.m

Outra possibilidade

% matriz de transição

T=[7 8; 3 2]/10;

% resolver equação $Au = b$

aux= (T-eye(length(T)));

% usa as primeiras linhas de T + equação $x_1 + x_2 = 1$

A= [aux(1:end-1,:); 1 1];

b= [0 1]';

u= inv(A)*b

...

- Pode também ser resolvido usando uma matriz aumentada e a função **rref()**

`%Matlab`

`C= [M x]`

`rref(C)`

$$\left(\begin{array}{cc|c} -3/10 & 8/10 & 0 \\ 3/10 & -8/10 & 0 \\ 1 & 1 & 1 \end{array} \right) \rightsquigarrow \left(\begin{array}{cc|c} 1 & 0 & 8/11 \\ 0 & 1 & 3/11 \\ 0 & 0 & 0 \end{array} \right)$$

- Mais informação:
<https://www.math.ucdavis.edu/~daddel/MATH22AL/LABS/LAB2/lab2.pdf>

Exemplo 2


- Aplicando a última técnica ao nosso exemplo 2 (grupos) teremos

$$\left(\begin{array}{ccc|c} -2/3 & 1/4 & 0 & 0 \\ 1/3 & -1/2 & 1/2 & 0 \\ 1/3 & 1/4 & -1/2 & 0 \\ 1 & 1 & 1 & 1 \end{array} \right) \rightsquigarrow \left(\begin{array}{ccc|c} 1 & 0 & 0 & 3/17 \\ 0 & 1 & 0 & 8/17 \\ 0 & 0 & 1 & 6/17 \\ 0 & 0 & 0 & 0 \end{array} \right)$$

Cadeias com estados absorventes

Estados absorventes

- Um **estado absorvente** é um estado do qual não é possível sair (ou seja transitar para outro estado)



- Os estados 0 e 4 são absorventes


Cadeias absorventes

- Uma **cadeia** é **absorvente** se:

(1) tiver pelo menos um estado absorvente

(2) é possível ir de cada um dos estados não absorventes para pelo menos um dos estados absorventes num número finito de passos.

Exemplo simples



Demo

- Absorbing Markov Chain
 - <http://demonstrations.wolfram.com/AbsorbingMarkovChain/>